

WM 算法

1. WM (Wu-Manber) 算法的简单理解:

(1) WM 算法需要的参数:

Σ : 字母集

c: 字母集数目

m: 模式串集合中, 字符串长度最小的模式串的长度

B: 字符块长度, 是 shift 表的索引, 一般取 2 或者 3

h: 当前扫描过程中长度为 B 的模式串子串

T: 文本串

N: 文本串总长度

P = {P1, P2, ..., Pk}: 模式串集合

k: 模式串的数目

C: 前缀长度 (PREFIX 表使用)

(2) WM 算法的时间复杂度:

O (BN/kM), 由此可以看出, WM 适用于大规模的模式串集合且模式串集合中最小长度较大的场景!

(3) WM 算法的核心思想:

WM 算法是对 BM 算法的延伸继承, 用 BM 算法的核心框架, 用字符块来计算 shift 表 (取代坏字符表) 进行跳转, 在进行匹配时, 用 hash 和 prefix 计算前后缀的 hash 值来从众多可选的模式串中快速筛选出正确匹配的模式串。

(4) WM 算法的三张核心表:

shift 表: 用于记录文本串向右移动的长度, 即一张跳转表 (ps: 有点类似 BM 算法的坏字符表, 不过 BM 是针对单字符, WM 是针对字符块)。

hash 表: hash 表记录了所有模式串后缀 (长度为 B) 与模式串本身的映射关系。当 shift[h]=0 时, B 与对应模式串 P 的映射关系, 但是存在一对多的映射, 因为模式串集合中存在相同后缀的模式串, 所以 hash 表的 value 应该是一个链表的形式, 存储多个模式串 (ps: 当 shift[h]=0 时, 说明匹配到了某模式串, 此时要用 hash 表查匹配到了哪个模式串 P)

prefix 表: prefix 记录了所有模式串前缀 (长度为 B) 与模式串本身的映射关系。同 hash 表一样, B 与对应模式串 P 的映射关系存在一对多, 所以 prefix 表的 value 也是一个链表的形式, 存储多个模式串。 (ps: hash 与 prefix 两个表取交集极大地缩小了需要匹配的次数)

2. WM (Wu-Manber) 算法的匹配过程:


当 B 个字符构成的子串 h 在模式串集合中没有匹配, 即 shift[h]<0, 则跳转的距离是: m-B+1 (相对保守的策略)

当 B 个字符构成的子串 h 在模式串集合中有匹配且非后缀, 即 shift[h]>0, 则跳转的距离是: shift[h] (相对安全的滑动)

当 B 个字符构成的子串 h 在模式串集合中且是后缀, 即 shift[h]=0, 则查 hash 和 prefix 表确定匹配到了哪个模式串

3. WM (Wu-Manber) 算法的简单例子 (来自 joylnwang 专栏-WM 算法详解):

目标串 target[1...10]=dcbacabcde, 模式集合 P={abcde, bcbde, adcabe} (ps: m=5, B=2, k=3, C=2), 预处理后得到的三张表如下所示:



WM 算法的匹配过程是：

- (1) 从 $i=5$ (因为 $m=5$) 开始执行算法, 首先我们发现 $\text{target}[4...5] = \text{ac}$ ($\text{target}[i-B+1](5-2+1)$), SHIFT 表中不存在 ac , 所以 $i = i+4$ (shift 表中没找到, 则 $i += m-B+1$)
- (2) 此时 $i=9$, 发现 $\text{target}[8...9] = \text{cd}$, 查 $\text{SHIFT}[\text{cd}] = 1$, 所以 $i += \text{SHIFT}[\text{cd}]$ 。
- (3) 此时 $i=10$, 然后发现 $\text{target}[9...10] = \text{de}$, 查 $\text{SHIFT}[\text{de}] = 0$, 表明可能出现匹配到模式串的情况。
- (4) 查 $\text{HASH}[\text{de}]$ 有两个模式串 abcde 和 bcbde ; 在 target 中取长度为 C 的从 $i-m+1$ 开始的子串, 即 $\text{target}[6...7] = \text{ab}$, 查 $\text{PREFIX}[\text{ab}] = \text{abcde}$ 。此时确定模式串是 abcde 。

朴素贝叶斯分类器

$$P(H | X) = \frac{P(X | H) P(H)}{P(X)}$$

$$P(H | X) = \frac{P(X | H) P(H)}{\sum_{|H|} P(H) P(X | H)}$$

$$P(H | X) = \frac{P(H) \prod_{k=1}^n P(x_k | H)}{\sum_{|H|} P(H) \prod_{k=1}^n P(x_k | H)}$$

【例】

<i>RID</i>	<i>age</i>	<i>income</i>	<i>student</i>	<i>credit_rating</i>	<i>Class:buys_computer</i>
1	youth	high	no	fair	no
2	youth	high	no	excellent	no
3	middle_aged	high	no	fair	yes
4	senior	medium	no	fair	yes
5	senior	Low	yes	fair	yes
6	senior	Low	yes	excellent	no
7	middle_aged	low	yes	excellent	yes
8	youth	medium	no	fair	no
9	youth	low	yes	fair	yes
10	senior	medium	yes	fair	yes
11	youth	medium	yes	excellent	yes
12	middle_aged	medium	no	excellent	yes
13	middle_aged	high	yes	fair	yes
14	senior	medium	no	excellent	no

已知某人: age = 22, income = medium, student = yes, credit_rating = fair
预测是否 buys_computer

我们需要最大化 $P(X | C)P(C)$, $i = 1, 2$ 。每个类的先验概率 $P(C_i)$ 可以根据训练样本计算:

$$P(\text{buys_computer} = \text{"yes"}) = 9/14 = 0.643$$

$$P(\text{buys_computer} = \text{"no"}) = 5/14 = 0.357$$

为计算 $P(X | C)$, $i = 1, 2$, 我们计算下面的条件概率:

$$P(\text{age} = \text{"<30"} | \text{buys_computer} = \text{"yes"}) = 2/9 = 0.222$$

$$P(\text{age} = \text{"<30"} | \text{buys_computer} = \text{"no"}) = 3/5 = 0.600$$

$$P(\text{income} = \text{"medium"} | \text{buys_computer} = \text{"yes"}) = 4/9 = 0.444$$

$$P(\text{income} = \text{"medium"} | \text{buys_computer} = \text{"no"}) = 2/5 = 0.400$$

$$P(\text{student} = \text{"yes"} | \text{buys_computer} = \text{"yes"}) = 6/9 = 0.667$$

$$P(\text{student} = \text{"yes"} | \text{buys_computer} = \text{"no"}) = 1/5 = 0.200$$

$$P(\text{credit_rating} = \text{"fair"} | \text{buys_computer} = \text{"yes"}) = 6/9 = 0.667$$

$$P(\text{credit_rating} = \text{"fair"} | \text{buys_computer} = \text{"no"}) = 2/5 = 0.400$$

使用以上概率, 我们得到:

$$P(X | \text{buys_computer} = \text{"yes"}) = 0.222 \times 0.444 \times 0.667 \times 0.667 = 0.044$$

$$P(X | \text{buys_computer} = \text{"no"}) = 0.600 \times 0.400 \times 0.200 \times 0.400 = 0.019$$

$$P(X | \text{buys_computer} = \text{"yes"}) P(\text{buys_computer} = \text{"yes"}) = 0.044 \times 0.643 = 0.028$$

$$P(X | \text{buys_computer} = \text{"no"}) P(\text{buys_computer} = \text{"no"}) = 0.019 \times 0.357 = 0.007$$

因此, 对于样本 X , 朴素贝叶斯分类预测 $\text{buys_computer} = \text{"yes"}$ 。